

Obtención de Datos para el TFM

Análisis de mercado y factibilidad comercial del vino en Costa Rica 2025

Este documento resume el proceso de obtención, preparación y análisis exploratorio de datos para sustentar el Trabajo Fin de Máster. El entregable técnico se acompaña de un repositorio Python con arquitectura modular y datasets en CSV dentro de la carpeta results/.

Nota metodológica: los resultados de precios incluidos corresponden a una extracción inicial documentada a partir de páginas públicas indexadas de Walmart Costa Rica, Masxmenos Costa Rica y PriceSmart Costa Rica. Para la entrega final del TFM se recomienda ejecutar el pipeline directamente contra las páginas vivas, validar robots.txt y conservar fecha/hora de extracción.

1. Introducción

El proyecto busca evaluar la viabilidad comercial de un negocio de vino en Costa Rica. Para ello se requieren datos que permitan observar oferta, precios, presentación de productos, descuentos, variables macroeconómicas, comercio exterior, turismo y variables socioeconómicas. La combinación de web scraping, API y datos institucionales permite construir una base más robusta que un simple dataset descargado.

2. Fuentes utilizadas y evaluadas

Se evaluaron fuentes de tres tipos: web scraping de comercios minoristas, APIs o servicios institucionales para variables macro, y portales de datos abiertos o reportes institucionales para importaciones, turismo y segmentación socioeconómica.

Fuente	Tipo	Variables meta útiles	Estado
BCCR	API/Web Service	tipo_cambio_compra, tipo_cambio_venta, IPC, IMAE, comercio_exterior	Viable
PROCOMER	ODATA / portal estadístico	importaciones por partida, valor CIF, volumen, pais_origen, periodo	Viable con exploración técnica
COMEX	Portal / enlaces institucionales	importaciones, mercado_origen, partidas arancelarias, regímenes	Viable como fuente institucional complementaria
INEC	Open data	población, ingresos, gasto hogares, variables socioeconómicas	Viable
INEC	Catálogo / microdatos	encuestas, censos, metadatos, variables demográficas	Viable
ICT	PDF/Excel/portal	llegadas turistas, pais_origen, puesto_migratorio, actividad turística	Viable como extracción de archivos
Walmart Costa Rica	Web scraping	producto, precio, presentacion, categoria, descuento	Viable
Masxmenos Costa Rica	Web scraping	producto, precio, presentacion, categoria, descuento	Viable
PriceSmart Costa Rica	Web scraping	producto, precio, presentacion, categoria	Parcialmente viable

3. Proceso de extracción

Para precios de mercado se definió un scraper modular por retailer/categoría, con configuración externa en YAML, cabeceras identificables, pausas entre solicitudes y normalización posterior. El objetivo no es solo obtener precios, sino dejar trazabilidad de comercio, categoría, URL de origen, fecha de extracción y presentación en mililitros. Para variables macro se dejó implementado un extractor BCCR parametrizable por indicador, fecha inicial y fecha final. Para PROCOMER/COMEX, INEC e ICT se construyó una matriz de factibilidad porque algunas fuentes publican APIs, ODATA, Excel/PDF o portales que deben explorarse con endpoints específicos antes de automatizarse completamente.

4. Arquitectura de software propuesta

La solución se organizó con separación de responsabilidades: extractores, transformadores, análisis, utilidades y configuración. Esta arquitectura facilita extender nuevas fuentes, reemplazar selectores por retailer, automatizar ejecuciones y mantener reproducibilidad. Buenas prácticas aplicadas: configuración fuera del código, funciones pequeñas, generación de outputs en results/, diccionario de variables, reporte de calidad, notebook reproducible y PDF sin código.


5. Limpieza y preparación del dataset


Se eliminaron duplicados por comercio, producto normalizado y precio; se imputó el precio final tomando precio de oferta cuando existía y precio de lista en caso contrario; se convirtieron precios a formato numérico; se normalizaron productos a precio equivalente de 750 ml; y se clasificaron segmentos de precio en económico, medio, premium y super premium.

Métrica	Valor
filas_raw	44.0
filas_clean	43.0
duplicados_raw	0.0
faltantes_precio_final_raw	1.0
retailers	3.0
categorias	3.0
precio_min_750ml	1747.5
precio_promedio_750ml	6801.92
precio_mediana_750ml	6110.0
precio_max_750ml	18495.0

6. Análisis exploratorio de datos

El dataset limpio contiene 43 observaciones válidas, 3 retailers y 3 categorías. El precio equivalente promedio por botella de 750 ml es de aproximadamente ■6,802, con una mediana de ■6,110.





7. Resultados principales

Los comercios observados muestran oferta en rangos económicos y medios, con productos premium más visibles en clubes de precio o categorías especializadas. La normalización a 750 ml es indispensable porque existen botellas de 375 ml, 750 ml, 1000 ml, 1500 ml y multipacks. Los descuentos observados son relevantes para estudiar elasticidad promocional y estrategia de precios.

Retailer	Categoría	Productos	Precio prom. 750ml
Masxmenos Costa Rica	Vino blanco	8	■4,454
Masxmenos Costa Rica	Vino rosado	8	■8,448
Masxmenos Costa Rica	Vino tinto	4	■7,550
PriceSmart Costa Rica	Vino blanco	2	■6,345
PriceSmart Costa Rica	Vino rosado	2	■6,795
PriceSmart Costa Rica	Vino tinto	7	■10,414
Walmart Costa Rica	Vino blanco	1	■8,800
Walmart Costa Rica	Vino rosado	1	■5,460
Walmart Costa Rica	Vino tinto	10	■4,564

8. Uso inicial de Streamlit

Se propone un tablero inicial en Streamlit para filtrar productos por retailer, categoría, segmento de precio y presentación, permitiendo observar rangos de mercado y comparar comercios antes de construir modelos predictivos o dashboards finales de BI.

9. Limitaciones y consideraciones éticas

Las páginas de retail pueden cambiar selectores, precios o disponibilidad. Algunas fuentes pueden requerir token, sesión o descarga manual de archivos. El scraping debe respetar términos de uso, robots.txt, frecuencia razonable y fines académicos. Para productos alcohólicos, el análisis debe limitarse a investigación de mercado y no a promoción de consumo irresponsable.

10. Conclusión

El trabajo deja una base inicial robusta para el TFM: precios reales observados, matriz de APIs/fuentes institucionales, arquitectura reproducible y datasets CSV listos para análisis. La siguiente fase debe automatizar la extracción periódica, incorporar importaciones por partida arancelaria, cruzar tipo de cambio e inflación, y enriquecer el modelo con variables socioeconómicas y turísticas.

Referencias y fuentes web verificadas

Banco Central de Costa Rica. Indicadores Económicos - APIs: <https://www.bccr.fi.cr/indicadores-economicos/Paginas/APIs.aspx>
BCCR. Webservice de indicadores económicos: https://gee.bccr.fi.cr/indicadoreseconomicos/Documentos/DocumentosMetodologiasNotasTecnicas/Webservices_de_indicadores_economicos.pdf
PROCOMER. Portal Estadístico de Comercio Exterior: <https://servicios.procomer.go.cr/PortalEstadistico/>
INEC. Datos Abiertos: <https://datosabiertos.inec.cr/>
ICT. Cifras Turísticas: <https://www.ict.go.cr/es/administrar-estadistica/cifras-tur%C3%ADsticas.html>
Walmart Costa Rica. Categorías de vinos: <https://www.walmart.co.cr/cervezas-vinos-y-licores/vinos>
Masxmenos Costa Rica. Categorías de vinos: <https://www.masxmenos.cr/cervezas-vinos-y-licores/vinos>
PriceSmart Costa Rica. Categorías de vinos: <https://www.pricemart.com/es-cr/categoria/Licor-cerveza-y-vino-G10D08014/G10D08014>